Projet 8 - Déployez un modèle dans le cloud

Création d'une architecture Big Data dans un environnement AWS (EMR, S3, IAM) via des scripts PySpark pour préparer le passage à l'échelle en termes de volume de données
Lien livrables en fin de présentation

01/08/2023

Sommaire

- Rappel de la problématique
- Présentation du jeu de données
- Processus de création de l'environnement Big Data, S3 et EMR
- Réalisation de la chaîne de traitement des images dans un environnement Big Data dans le Cloud
- Démonstration d'exécution du Script PySpark

puis remarques & axes d'amélioration.

Rappel de la Problématique

Rappel de la problématique

Fruits!

La start-up : Fruits! est une start-up de l'AgriTech qui souhaite proposer des solutions innovantes pour la récolte des fruits.

Concept : Développer des robots cueilleurs intelligents pour préserver la biodiversité des fruits en permettant des traitements spécifiques.

Objectif : Se faire connaître en mettant à disposition une app mobile pour que les users (grand public) puisse obtenir des informations sur le fruit pris en photo.

Solution : Mise en place d'une première version du moteur de classification des images de fruits, d'une première version de l'architecture Big Data nécessaire.

Contraintes :

- Le volume de données va augmenter très rapidement
- RGPD - serveurs européens
- Les coûts à surveiller

Présentation du jeu de données

Présentation du jeu de données

- **Source du jeu de données :** Kaggle
- **Type de données =** Images de fruits et de légumes sur fond blanc, sous différents angles, extraites de vidéos de type timelapse
- **Configuration du dossier :** chaque variété est un dossier qui comporte les photos de ladite variété
- **Type d'images =** JPG 100 x 100
- **Taille du dataset utilisé :** 22688 images

J'ai fait **2 itérations** du projet, la première fois j'ai utilisé seulement **3 variétés**, et seulement une partie des images donc **33** images au total

Blueberry

Pear Kaiser

Tomato Maroon

Processus de création de l'environnement Big Data, S3 et EMR

Une problématique Big Data

“Le volume de données va augmenter rapidement”

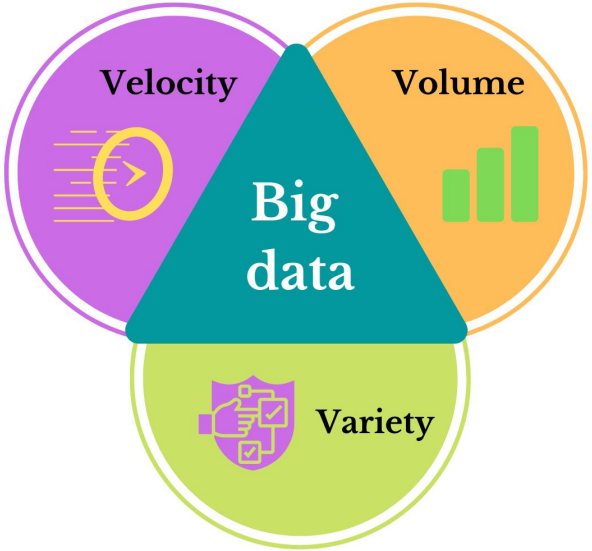

Apache Spark pour les calculs distribués

Les ressources d'une seule machine sont limitées et ne permettent pas d'effectuer un grand nombre de tâches.

Il faut diviser les tâches en sous-tâches et les distribuer (map) sur plusieurs machines, une fois effectuées il faut les réassembler (reduce).

C'est ce que permet de faire Apache Spark (ainsi qu'Hadoop).

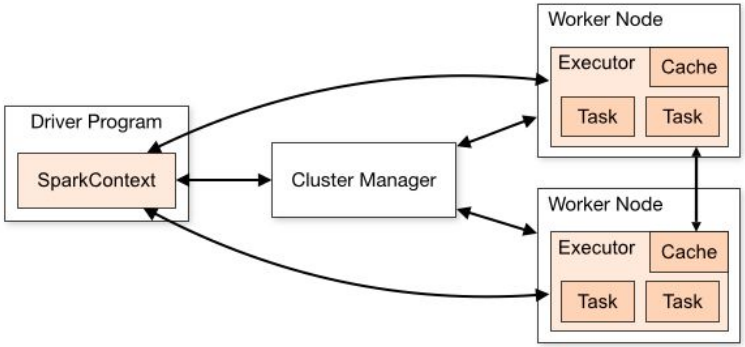

L'architecture retenue : les services Amazon

Cluster de machines redimensionnable selon la demande. Distribution des calculs sur instances EC2.

Accès Sécurisé via IAM
(Identity and Access Management)

RGPD
Données en Europe / Stockolm

Paramétrage du cluster

Informations sur le cluster

ID de cluster
j-3PFNW0WICHIJH

Configuration de cluster
Groupes d'instances

Capacité
1 primaire(s) 2 unité(s) principale(s) 0 tâche(s)

Applications

Version d'Amazon EMR
emr-6.3.0

Applications installées
Hadoop 3.2.1, JupyterHub 1.2.0, Spark 3.1.1, TensorFlow 2.4.1

Ubuntu

Connexion via tunnel SSH

avec Putty

puis FoxyProxy

Installation Bootstrap : action d'amorçage

```
#!/bin/bash
sudo python3 -m pip install -U setuptools
sudo python3 -m pip install -U pip
sudo python3 -m pip install wheel
sudo python3 -m pip install pillow
sudo python3 -m pip install pandas==1.2.5
sudo python3 -m pip install pyarrow
sudo python3 -m pip install boto3
sudo python3 -m pip install s3fs
sudo python3 -m pip install fsspec
```

Travail du script sur :

jupyterhub

Chaîne de traitement des images

Chaîne de traitement des images

1ère utilisation sur 22k images et entraînement de la PCA

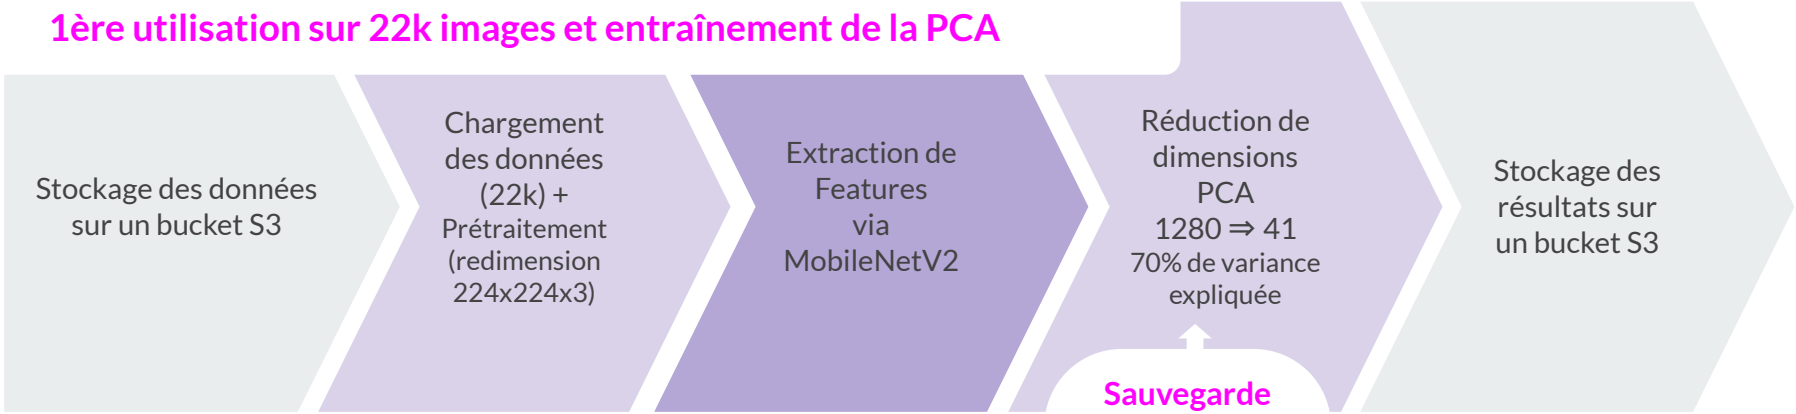

Sauvegarde de la PCA et réutilisation

Réutilisation test sur une sélection d'images avec import de la PCA

Zoom sur MobileNetV2

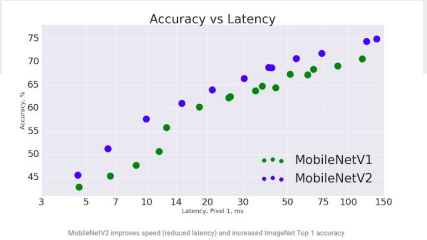

- Lancé par Google en 2018, version améliorée de MobileNetV1. Conçue pour fonctionner sur mobile.
- Les poids des modèles sont diffusés sur l'ensemble des nodes du cluster.
- Modèle pré-entraîné sur plus d'un million d'images classées en 1000 catégories différentes : on peut extraire des features sans entraînement.
- Convolutional Neural Network (CNN), Linear Bottlenecks (X fonction d'activation), Inverted Residuals
- Conservation de l'avant dernière couche (et non celle de classification - softmax)
- 1280 features en sortie

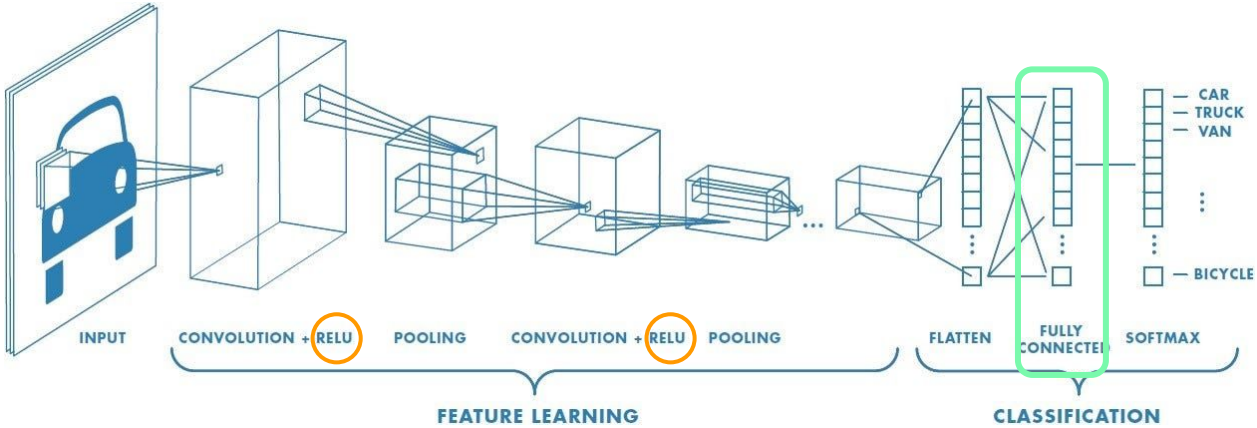


Démonstration

Inventaire du bucket sur test partiel (33 images)

/root :
- Result/
- Test/
- final_features.csv/
- jupyter/

/Result :
- _SUCCESS
- part-00000-3b1a07d5-c784-4322-b5db-f25e165c3d41-c000.snappy.parquet
- part-00001-3b1a07d5-c784-4322-b5db-f25e165c3d41-c000.snappy.parquet
- part-00002-3b1a07d5-c784-4322-b5db-f25e165c3d41-c000.snappy.parquet
- part-00003-3b1a07d5-c784-4322-b5db-f25e165c3d41-c000.snappy.parquet
...
- part-00014-3b1a07d5-c784-4322-b5db-f25e165c3d41-c000.snappy.parquet
- part-00015-3b1a07d5-c784-4322-b5db-f25e165c3d41-c000.snappy.parquet
- part-00016-3b1a07d5-c784-4322-b5db-f25e165c3d41-c000.snappy.parquet
- part-00017-3b1a07d5-c784-4322-b5db-f25e165c3d41-c000.snappy.parquet
- part-00018-3b1a07d5-c784-4322-b5db-f25e165c3d41-c000.snappy.parquet
- part-00019-3b1a07d5-c784-4322-b5db-f25e165c3d41-c000.snappy.parquet
- part-00020-3b1a07d5-c784-4322-b5db-f25e165c3d41-c000.snappy.parquet

/Test :
- Blueberry/
- Pear Kaiser/
- Tomato Maroon/

/jupyter/jovyan :
- .s3keep
- Guarneri_Naomi_1_notebook_fruits_pyspark_072023.ipynb
- notebook.ipynb

Conclusions & Remarques

Visualisation de la classification non supervisée

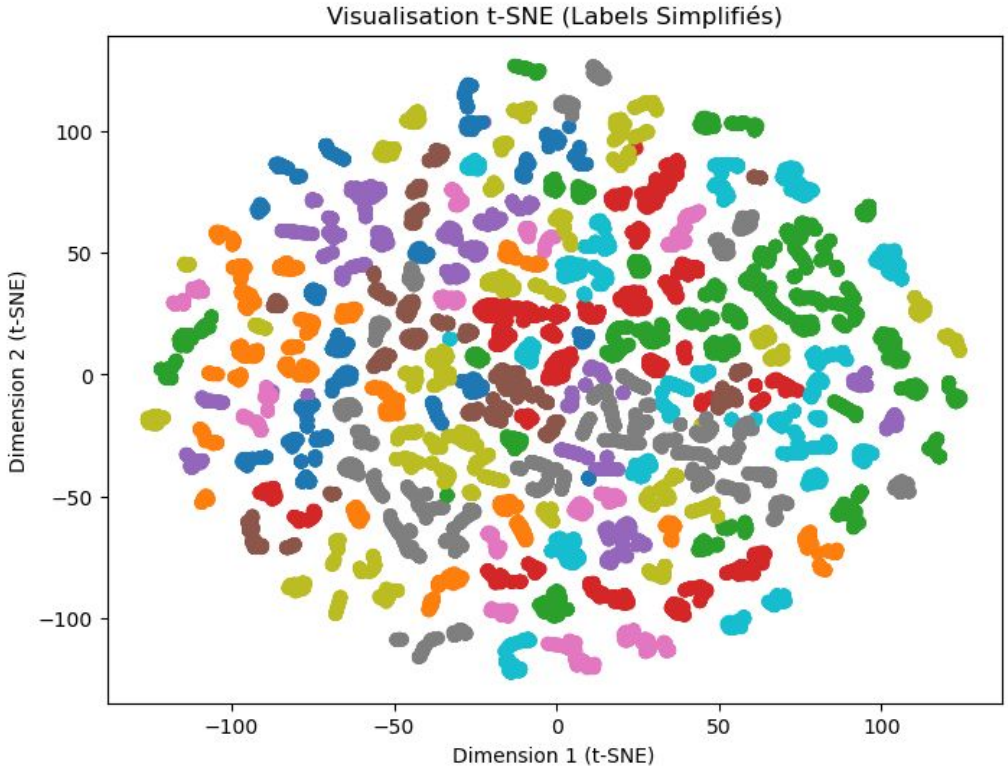

Conclusions & Remarques

Ce que nous soumettons :

- Une architecture qui permet une mise à l'échelle quand les données augmenteront, avec la possibilité d'augmenter automatiquement le nombre d'instances en fonction du nombre de données
- Une chaîne de traitement des images qui permet d'en extraire les features via MobileNetV2 et une réduction de dimension pour réduire le stockage

Difficultés rencontrées :

- Paramétrage de la console AWS complexe (énormément de possibilités)
- Difficile de savoir d'où viennent les problèmes, il faut faire preuve de persévérance

Pistes d'améliorations & idées :

- Exploiter les photos prises par les utilisateurs, donner un statut de contributeur, pour identifier les images avec faible taux de précision
- Identifier les fruits mûrs
- Identifier les maladies
- Possibilité de passer par Google Cloud Platform (Google Cloud Dataproc / Google Cloud Storage)

Lien livrables

- Lien du projet sur GitHub dont CSV de résultats
- Lien du drive avec images et CSV